

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

BỘ MÔN THỊ GIÁC MÁY TÍNH

Phân đoạn hình ảnh y khoa

Môn: Thị giác máy tính

Thông tin Sinh viên:

23127165 - Nguyễn Hải Đăng

23127181 - Nguyễn Trần Quốc Duy

Giảng viên:

Thầy Võ Hoài Việt

Thầy Phạm Minh Hoàng

Thầy Phạm Thanh Tùng

Ngày 17 tháng 3 năm 2026



Mục lục

1	Tóm tắt	2
2	Tên đề tài và Phương thức nghiên cứu	2
2.1	Tên đề tài	2
2.2	Phương thức nghiên cứu	2
3	Mục tiêu và Các bước nghiên cứu	2
3.1	Mục tiêu	2
3.2	Các bước nghiên cứu	3
4	Tổng quan về thực trạng và kiến thức/tài liệu có sẵn	3
4.1	Tầm quan trọng lâm sàng của phân đoạn polyp	3
4.2	Tiến hóa của kiến trúc phân đoạn	3
4.3	Pruning và Knowledge Distillation	4
4.4	Khoảng trống nghiên cứu	4
5	Tổng quan Phương pháp Đề xuất	4
6	Đóng góp Nghiên cứu Mong đợi	5
7	Phương pháp Nghiên cứu	6
7.1	Bộ dữ liệu	6
7.2	Chi tiết kiến trúc đề xuất	6
7.3	Cấu hình huấn luyện	8
7.4	Thiết kế Ablation Study	8
7.5	Metrics đánh giá	8
7.6	Những hạn chế có thể xảy ra	9
8	Kế hoạch thực hiện (8 tuần)	9
9	Tài nguyên	10
9.1	Tài nguyên tính toán	10
9.2	Phần mềm (tất cả mã nguồn mở)	10

1 Tóm tắt

Ung thư đại tràng là một trong những nguyên nhân gây tử vong hàng đầu do ung thư trên toàn thế giới. Phát hiện sớm polyp đại tràng qua nội soi là chiến lược phòng ngừa chủ yếu, tuy nhiên tỷ lệ bỏ sót polyp của bác sĩ có kinh nghiệm vẫn có thể vượt 20% do sơ suất của người chuẩn đoán và sự đa dạng về hình thái polyp. Các hệ thống phân đoạn ảnh tự động dựa trên deep learning đã đạt kết quả cao nhưng hầu hết quá nặng về mặt tính toán, không phù hợp triển khai thực tế trong phòng nội soi.

Nghiên cứu này đề xuất một phương pháp mới gồm 4 bước: (1) huấn luyện một mô hình Teacher mạnh (UNet + ResNet50); (2) áp dụng Structured Pruning có hướng dẫn để tìm ra kiến trúc tối ưu (blueprint); (3) xây dựng mô hình Student nhỏ gọn dựa trên blueprint đó; (4) huấn luyện Student với cơ chế Learnable Channel Gating kết hợp Knowledge Distillation và hàm mất mát tổng hợp ba thành phần ($L_{seg} + L_{distill} + L_{sparsity}$). Mục tiêu là đạt Dice ~ 0.88 – 0.91 với chỉ 3–5M tham số và tốc độ inference phù hợp thời gian thực.

Mô hình được đánh giá trên 5 bộ dữ liệu chuẩn: Kvasir-SEG và CVC-ClinicDB (train/test), CVC-ColonDB, ETIS và CVC-300 (zero-shot generalization). Metrics bao gồm Dice, IoU, HD95, Params, FLOPs và FPS. Kết quả kỳ vọng đầy khoảng trống giữa các model nhẹ (BiSe-UNet: Dice 0.78, 2.5M) và các model nặng SOTA (Polyp-PVT: Dice 0.917, hàng chục triệu params).

2 Tên đề tài và Phương thức nghiên cứu

2.1 Tên đề tài

Tối ưu kiến trúc UNet thông qua Pruning có hướng dẫn và Knowledge Distillation với Learnable Channel Gating cho phân đoạn Polyp Đại tràng trong thời gian thực

(Tiêu đề tiếng Anh: *Architecture-Aware Pruning and Knowledge Distillation with Learnable Channel Gating for Lightweight Real-Time Polyp Segmentation*)

2.2 Phương thức nghiên cứu

Nghiên cứu mang tính thực nghiệm và định hướng dữ liệu (data-driven experimental research). Các hoạt động chính bao gồm: (1) tổng quan tài liệu về kiến trúc lightweight, knowledge distillation và structured pruning trong phân đoạn ảnh y tế; (2) thu thập và tiền xử lý 5 bộ dữ liệu nội soi công khai; (3) cài đặt pipeline 4 bước bằng PyTorch; (4) đánh giá hệ thống so với các phương pháp SOTA; (5) viết và nộp bài báo theo chuẩn IEEE. Nghiên cứu yêu cầu tính toán hoàn toàn trên GPU (Google Colab Pro A100 hoặc tương đương).

3 Mục tiêu và Các bước nghiên cứu

3.1 Mục tiêu

Phát triển một mô hình deep learning nhỏ gọn, chính xác và có khả năng triển khai lâm sàng cho bài toán phân đoạn polyp đại tràng, đạt hiệu năng tương đương SOTA với chi phí tính toán giảm đáng kể thông qua việc kết hợp structured pruning, knowledge distillation và learnable channel gating.

3.2 Các bước nghiên cứu

1. Tìm hiểu và phân tích tổng quan tài liệu về: (a) kiến trúc UNet và các biến thể lightweight (BiSe-UNet, U-Net-MobileNetV2); (b) structured pruning và knowledge distillation trong phân đoạn ảnh y tế; (c) learnable gating và sparsity regularization trong deep learning.
2. Thu thập, phân tích và tiền xử lý 5 bộ dữ liệu: Kvasir-SEG, CVC-ClinicDB, CVC-ColonDB, ETIS và CVC-300 theo chuẩn phân chia train/val/test đã được công bố.
3. Huấn luyện mô hình Teacher (UNet + ResNet50) đạt hiệu năng baseline trên Kvasir-SEG và CVC-ClinicDB; ghi nhận kết quả làm mốc so sánh.
4. Thực hiện Structured Pruning có hướng dẫn (L1 Norm + BatchNorm γ criterion) để xác định kiến trúc rút gọn tối ưu (pruned blueprint) cho Student.
5. Thiết kế và cài đặt mô hình Student dựa trên blueprint từ bước pruning; tích hợp cơ chế Learnable Channel Gating (sigmoid-gated convolution).
6. Huấn luyện Student với hàm mất mát tổng hợp $L_{total} = L_{seg} + \lambda_1 \cdot L_{distill} + \lambda_2 \cdot L_{sparsity}$; thực hiện ablation study để xác định λ tối ưu.
7. Đánh giá toàn diện trên 5 datasets với các metrics: Dice, IoU, HD95, Params (M), FLOPs (G), FPS; so sánh với các phương pháp SOTA có nguồn trích dẫn rõ ràng.
8. Viết, chỉnh sửa và nộp bài báo; công bố mã nguồn và pretrained weights lên GitHub.

4 Tổng quan về thực trạng và kiến thức/tài liệu có sẵn

4.1 Tầm quan trọng lâm sàng của phân đoạn polyp

Ung thư đại tràng đứng thứ 3 về tỷ lệ mắc và thứ 2 về tỷ lệ tử vong do ung thư toàn cầu (WHO, 2022). Hầu hết ung thư đại tràng phát triển từ polyp lành tính theo con đường adenoma-carcinoma. Nội soi đại tràng là tiêu chuẩn vàng để phát hiện và cắt bỏ polyp, nhưng tỷ lệ bỏ sót có thể lên tới 20–28% ngay cả với bác sĩ có kinh nghiệm (van Rijn et al., 2006), do một mặt trong quá trình quan sát, polyp nhỏ và áp lực thời gian thực. Các hệ thống CADx (Computer-Aided Diagnosis) tự động phân đoạn polyp giúp cảnh báo bác sĩ theo thời gian thực — nhưng hệ thống yêu cầu inference rất nhanh (≥ 30 FPS) ngay cả khi trên các thiết bị phần cứng hạn chế.

4.2 Tiến hóa của kiến trúc phân đoạn

U-Net [11] được thiết lập nền tảng với encoder-decoder và skip connections, phù hợp cho dữ liệu y tế hạn chế. U-Net++ [14] cải thiện qua dense nested skip pathways. PraNet [3] đề xuất parallel reverse attention, đạt Dice 0.898 trên Kvasir-SEG. Polyp-PVT [2] dùng Pyramid Vision Transformer encoder, đạt SOTA 0.917 Dice trên Kvasir-SEG. TransFuse [13] kết hợp CNN và Transformer qua BiFusion module.

Tuy nhiên, các model SOTA này đều rất nặng (hàng chục đến hàng trăm triệu tham số), không phù hợp triển khai thực tế. Về phía lightweight, U-Net-MobileNetV2 [1] dùng MobileNetV2 làm encoder, đạt Dice 0.8971 trên Kvasir-SEG nhưng chưa đánh giá cross-dataset. BiSe-UNet [6] đề

xuất dual-path với DSConv decoder, đạt 30+ FPS trên Raspberry Pi 5 nhưng Dice chỉ 0.7809 — thấp hơn đáng kể so với SOTA.

4.3 Pruning và Knowledge Distillation


Structured pruning [4] [8] loại bỏ filter/channel ít quan trọng dựa trên L1 norm hoặc BatchNorm scaling factor γ , giảm số params mà không làm thay đổi cấu trúc tổng thể. Knowledge Distillation [5] cho phép một model học (student) học từ model lớn (teacher) qua soft labels và intermediate feature maps. Tuy nhiên, các phương pháp này chủ yếu được nghiên cứu trong natural image classification; ứng dụng vào phân đoạn polyp với learnable gating thì vẫn còn là khoảng trống chưa có nhiều nghiên cứu triển khai.

4.4 Khoảng trống nghiên cứu

Sau quá trình đọc và phân tích nhiều tài liệu và bài báo nghiên cứu khoa học, chúng em rút ra được 3 khoảng trống rõ ràng: (1) chưa có phương pháp tự động tìm kiến trúc lightweight tối ưu cho polyp segmentation bằng pruning, thay vì thiết kế thủ công, dẫn đến khả năng tồn tại các layer dư thừa và gây lãng phí tài nguyên; (2) Learnable channel gating chưa được áp dụng trong U-Net-based polyp segmentation; (3) Không có model lightweight nào được đánh giá đầy đủ trên cả 5 benchmark datasets chuẩn của field.

5 Tổng quan Phương pháp Đề xuất

Hình 1 mô tả tổng quan quy trình nghiên cứu toàn diện gồm 4 giai đoạn. Từ việc chuẩn bị dữ liệu (1), đề tài tập trung vào việc áp dụng Pruning trên mô hình Teacher để trích xuất blueprint tối ưu (2). Dựa vào đó, một Student nhỏ gọn được xây dựng và huấn luyện kết hợp cơ chế Learnable Gating cùng Knowledge Distillation (3), hướng tới kết quả đầu ra là một mô hình nhẹ, đạt chuẩn thời gian thực (4).



Hình 1: Tổng quan 4 bước pipeline của phương pháp đề xuất

- **(1) Data Input & Preprocessing:** Tiền xử lý và tăng cường 5 bộ dữ liệu nội soi (Kvasir-SEG, CVC-ClinicDB, ...).
- **(2) Built Pruned Skeleton:** Rút trích kiến trúc tối ưu (blueprint) từ Teacher thông qua Structured Pruning.
- **(3) Compression Training & Distillation:** Huấn luyện Student sử dụng Learnable Channel Gating và Hàm mất mát tổng hợp (L_{Total}).
- **(4) Evaluation & Output:** Suy luận và đánh giá toàn diện các metrics (Dice, IoU, FLOPs, FPS, ...).

Điểm khác biệt cốt lõi so với các nghiên cứu hiện có (BiSe-UNet, U-Net-MobileNetV2) là thay vì thiết kế kiến trúc lightweight theo cách thủ công, phương pháp này dùng dữ liệu để TỰ ĐỘNG tìm ra kiến trúc tối ưu qua pruning, sau đó dùng learnable gating để mô hình tiếp tục TỰ HỌC cần giữ hay bỏ kernel nào trong quá trình training.

6 Đóng góp Nghiên cứu Mong đợi

Nghiên cứu này dự kiến đóng góp các điểm mới sau:

- **Đóng góp 1:** Phương pháp tìm kiến trúc tự động: Thay vì thiết kế tay, dùng structured pruning (L1 norm + BatchNorm γ) trên Teacher để tự động tìm ra kiến trúc Student tối ưu (pruned blueprint). Đây là cách tiếp cận data-driven cho architecture search trong polyp segmentation, chưa xuất hiện trong literature.
- **Đóng góp 2:** Learnable Channel Gating trong U-Net: Tích hợp cơ chế gate = $\text{sigmoid}(\alpha) \times \text{conv}(x)$ vào từng convolution block của Student, cho phép model tự học cần giữ hay bỏ kernel trong quá trình training với sparsity regularization. Khác với pruning tính một lần, gating này là động và học được.
- **Đóng góp 3:** Hàm mất mát tổng hợp có lý giải: $L_{total} = L_{seg} + \lambda_1 \cdot L_{distill} + \lambda_2 \cdot L_{sparsity}$, trong đó mỗi thành phần có vai trò rõ ràng và được validate qua ablation study với báo cáo λ tối ưu.
- **Đóng góp 4:** Đánh giá toàn diện trên 5 datasets: Lần đầu tiên một lightweight polyp segmentation model được đánh giá đầy đủ trên cả 5 benchmark chuẩn (Kvasir-SEG, CVC-ClinicDB, CVC-ColonDB, ETIS, CVC-300) kết hợp với efficiency metrics (Params, FLOPs, FPS).
- **Đóng góp 5:** Tái hiện và so sánh minh bạch: Tất cả số liệu SOTA trong bảng so sánh đều được trích dẫn trực tiếp từ paper gốc, không dùng số ước tính. Code và pretrained weights được công bố công khai.

7 Phương pháp Nghiên cứu

7.1 Bộ dữ liệu


Nghiên cứu sử dụng 5 bộ dữ liệu nội soi đại tràng công khai:

Dataset	Số ảnh	Độ phân giải	Đặc điểm	Vai trò
Kvasir-SEG	1,000	Variable	Đa dạng hình thái	Train + Test chính
CVC-ClinicDB	612	384×288	Từ video sequences	Train + Test chính
CVC-ColonDB	380	500×570	Khác scanner/BV	Zero-shot test
ETIS	196	966×1225	Polyp nhỏ, khó	Zero-shot test (hard)
CVC-300	60	500×574	Tập validate nhỏ	Zero-shot test

Bảng 1: Bảng mô tả các bộ dữ liệu sử dụng trong nghiên cứu

Chiến lược phân chia dữ liệu: Kvasir-SEG và CVC-ClinicDB được chia 80% train / 10% val / 10% test theo seed cố định (seed=42). Ba datasets còn lại (CVC-ColonDB, ETIS, CVC-300) chỉ dùng hoàn toàn cho inference zero-shot để đánh giá khả năng tổng quát hóa. Tiền xử lý bao gồm resize về 352×352, chuẩn hóa ImageNet statistics, augmentation (flip, rotation $\pm 30^\circ$, color jitter, elastic deformation).

7.2 Chi tiết kiến trúc đề xuất



Hình 2: Chi tiết kiến trúc Teacher → Student với Learnable Gate (minh họa tổng quan)

Bước 1: Huấn luyện Teacher

Bước đầu sẽ chọn ResNet152, tuy nhiên tùy vào thực nghiệm có thể chọn sử dụng U-Net với backbone ResNet50 pretrained ImageNet. ResNet50 (~25M params) được chọn thay vì ResNet152

vì dataset polyp nhỏ (~ 1600 ảnh training) — teacher quá nặng có nguy cơ overfit và truyền noise sang student. Teacher được train đến convergence trên Kvasir-SEG + CVC-ClinicDB, kết quả được freeze (không update weights) trong các bước sau.

Bước 2: Structured Pruning $\rightarrow$ Blueprint

Áp dụng structured pruning trên Teacher để đánh giá độ quan trọng của từng filter/channel:

- **Tiêu chí (1) — L1 Norm:** $importance_i = \|W\|_1$, filter có norm nhỏ $\rightarrow$ ít đóng góp $\rightarrow$ ứng viên loại bỏ
- **Tiêu chí (2) — BatchNorm γ :** $importance_i = \|\gamma\|_1$, giá trị nhỏ $\rightarrow$ scale feature map gần 0 $\rightarrow$ có thể loại bỏ

Sau khi sắp xếp theo importance, loại bỏ 40–60% channels thấp nhất ở mỗi layer. Kết quả là một **pruned blueprint** — ví dụ từ $[64 \rightarrow 128 \rightarrow 256 \rightarrow 512]$ thành $[32 \rightarrow 64 \rightarrow 128 \rightarrow 256]$. Blueprint này là trực tiếp khởi tạo cấu trúc Student, không phải thiết kế tay.

Bước 3: Xây dựng Student

Student được khởi tạo từ blueprint thu được ở bước 2. Khác biệt so với Teacher ở chỗ mỗi convolution block được bọc thêm một Learnable Gate:

$$gate_i = \text{sigmoid}(\alpha_i)$$

$$output = gate_i \times conv(x)$$

Trong đó α_i là tham số học được (scalar per channel), sigmoid đưa về khoảng (0,1). Khi $gate_i \approx 1$: kernel được giữ nguyên. Khi $gate_i \approx 0$: kernel bị tắt dần — tương đương pruning động trong quá trình training. Cơ chế này cho phép Student tự điều chỉnh kiến trúc của mình trong khi train, thay vì chỉ nhận blueprint cố định.

Bước 4: Huấn luyện Student với Distillation + Learnable Gating

Student được tối ưu đồng thời bằng hàm mất mát 3 thành phần:

$$L_{total} = L_{seg} + \lambda_1 \cdot L_{distill} + \lambda_2 \cdot L_{sparsity}$$

- L_{seg} = Dice Loss + Binary Cross-Entropy: đảm bảo segmentation chính xác, xử lý class imbalance (Dice) và cung cấp gradient ổn định (BCE).
- $L_{distill} = \|F_{student} - F_{teacher}\|_2$: student học bắt chước intermediate feature maps của teacher, giữ lại kiến trúc của model lớn.
- $L_{sparsity} = \sum |gate_i|$: áp các gate về gần 0 để tiếp tục sparse hóa model, kết hợp với blueprint từ bước 2.

Các siêu tham số λ_1 và λ_2 được xác định qua ablation study (grid search trong $\{0.1, 0.3, 0.5\}$). Weights của Teacher được freeze hoàn toàn trong bước này.

7.3 Cấu hình huấn luyện

Siêu tham số	Giá trị
Kích thước input	352 × 352 px
Batch size	16
Optimizer	AdamW ($\beta_1=0.9$, $\beta_2=0.999$, weight_decay=1e-4)
Learning rate	1e-4 với CosineAnnealingLR
Số epochs	Teacher: 100 Student: 150
Encoder Teacher	ResNet50 pretrained ImageNet
Pruning ratio	40–60% channels/layer (grid search)
λ_1 (distillation)	Ablation: {0.1, 0.3, 0.5}
λ_2 (sparsity)	Ablation: {0.1, 0.3, 0.5}
Framework	PyTorch 2.x + MONAI
Hardware	NVIDIA A100 (Google Colab Pro)
Thời gian train ước tính	Teacher: ~3h Student: ~4h/run

Bảng 2: Cấu hình huấn luyện

7.4 Thiết kế Ablation Study

Để chứng minh từng thành phần đóng góp, 6 variants được train và đánh giá:

Experiment	Blueprint (Pruning)	Learnable Gating	Distill ($L_{distill}$)	Sparsity ($L_{sparsity}$)
Exp 1 — Teacher (baseline)	✗	✗	✗	✗
Exp 2 — Student (random init)	✗	✗	✗	✗
Exp 3 — Pruned Student (no gate)	✓	✗	✗	✗
Exp 4 — Pruned + Distillation	✓	✗	✓	✗
Exp 5 — Pruned + Gate + Sparsity	✓	✓	✗	✓
Exp 6 — Full Model (đề xuất)	✓	✓	✓	✓

Bảng 3: Bảng đánh giá các variants trong Ablation Study

7.5 Metrics đánh giá

Các metrics đánh giá được sử dụng trong nghiên cứu bao gồm:

Metric	Nhóm	Ý nghĩa
Dice (DSC)	Accuracy	Primary metric chuẩn của field, độ overlap giữa prediction và ground truth
IoU (Jaccard)	Accuracy	Metric overlap bổ sung, luôn đi kèm Dice trong polyp segmentation
HD95	Boundary	Đo sai lệch tại viền, quan trọng với polyp hình dạng bất thường
Params (M)	Efficiency	Số tham số mô hình — core contribution của paper
FLOPs (G)	Efficiency	Chi phí tính toán — chứng minh lightweight
FPS	Efficiency	Tốc độ inference — chứng minh real-time feasibility (target ≥ 30 FPS)

Bảng 4: Các metrics đánh giá được sử dụng trong nghiên cứu

7.6 Những hạn chế có thể xảy ra

- Xử lý ảnh 2D từng frame bỏ mất thông tin temporal từ video nội soi — đề xuất như khung mở rộng tương lai (2.5D hoặc video-based).
- Kvasir-SEG và CVC-ClinicDB tương đối nhỏ — kết quả generalization trên ETIS và ColonDB sẽ cho thấy giới hạn thực sự của model.
- Tỷ lệ pruning tối ưu cần được xác định qua thực nghiệm — không thể đảm bảo trước kết quả cụ thể.
- Balance giữa 3 loss components (λ_1, λ_2) nhạy cảm và cần ablation kỹ — tốn thời gian tính toán.
- Chưa thể ứng dụng ra thực tế trong trên các thiết bị edge trong điều kiện realtime.

8 Kế hoạch thực hiện (8 tuần)

Tuần	Giai đoạn	Công việc chi tiết
Tuần 1	Chuẩn bị	Đọc 15+ paper liên quan (U-Net variants, pruning, distillation, polyp segmentation); tải và kiểm tra 5 datasets; setup môi trường PyTorch + MONAI trên Colab; cài đặt evaluation pipeline (Dice, IoU, HD95, FPS).
Tuần 2	Teacher	Cài đặt và train Teacher (U-Net + ResNet50) trên Kvasir-SEG + CVC-ClinicDB; verify kết quả so với paper gốc; freeze Teacher weights.
Tuần 3	Pruning	Cài đặt structured pruning (L1 norm + BN γ); thử nghiệm tỷ lệ prune 30/40/50/60%; chọn blueprint tối ưu dựa trên Dice-vs-Params tradeoff; train Exp 2 & 3.
Tuần 4	Student + Gate	Xây dựng Student từ blueprint; cài đặt Learnable Channel Gating; train với L_seg đơn thuần trước; train Exp 4 & 5 với distillation và sparsity.
Tuần 5	Full Model + Ablation	Train Exp 6 (Full Model); ablation λ_1, λ_2 ; chạy inference trên cả 5 datasets; đo FPS và Params; so sánh với SOTA từ paper gốc.
Tuần 6	Viết paper	Viết IEEE format paper: Abstract, Introduction, Related Work, Methodology, Experiments & Results, Conclusion; vẽ figures và tables chuẩn IEEE.
Tuần 7	Chỉnh sửa	Review nội bộ với GV hướng dẫn (nếu có); chỉnh sửa manuscript; kiểm tra IEEE formatting guidelines; proofreading tiếng Anh.
Tuần 8	Nộp	Final proofread; submit lên Moodle; đẩy code lên GitHub với README và pretrained weights; lưu trữ toàn bộ experiment logs.

Bảng 5: Kế hoạch Thực hiện (8 tuần)

9 Tài nguyên

9.1 Tài nguyên tính toán

Toàn bộ nghiên cứu được thiết kế để chạy được trên Google Colab Pro (NVIDIA A100, 40GB VRAM). Ước tính tổng GPU hours: Teacher training ($\sim 3h$) + Pruning experiments ($\sim 4h$) + Student ablation 6 variants $\times 4h = 31h$. Với Colab Pro ($\sim \$10/\text{tháng}$), đây là ngân sách hoàn toàn khả thi.

9.2 Phần mềm (tất cả mã nguồn mở)

- PyTorch 2.x — framework deep learning chính
- MONAI — thư viện deep learning cho ảnh y tế
- segmentation-models-pytorch — tích hợp ResNet50 encoder
- Albumentations — augmentation pipeline
- torch-pruning — structured pruning utilities
- Weights & Biases (wandb) — theo dõi experiment
- matplotlib, seaborn — visualization kết quả

Tài liệu

- [1] M. V. L. Branch and A. dos S. Carvalho, "Polyp Segmentation in Colonoscopy Images using U-Net-MobileNetV2" *Federal University of Santa Catarina*, 2022.
- [2] B. Dong *et al.*, "Polyp-PVT: Polyp segmentation with pyramid vision transformers" arXiv:2108.06932, 2021.
- [3] D.-P. Fan *et al.*, "PraNet: Parallel reverse attention network for polyp segmentation" in *MIC-CAI 2020*, LNCS vol. 12266, pp. 263–273, 2020.
- [4] S. Han *et al.*, "Learning both weights and connections for efficient neural networks" *NeurIPS*, 2015.
- [5] G. Hinton, O. Vinyals, and J. Dean, "Distilling the knowledge in a neural network" *NeurIPS Deep Learning Workshop*, 2015.
- [6] M. I. Hossain and L. J. Brattain, "BiSe-UNet: A lightweight dual-path U-Net with attention-refined context for real-time medical image segmentation" arXiv:2603.00119, 2026.
- [7] D. Jha *et al.*, "Kvasir-SEG: A segmented polyp dataset" in *MMM 2020*, pp. 451–462, 2020.
- [8] H. Li *et al.*, "Pruning filters for efficient ConvNets" *ICLR*, 2017.

- [9] M. Mansoori *et al.*, "Polyp SAM 2: Advancing zero-shot polyp segmentation in colorectal cancer detection" arXiv:2408.05892, 2024.
- [10] O. Oktay *et al.*, "Attention U-Net: Learning where to look for the pancreas" *MIDL*, 2018.
- [11] O. Ronneberger, P. Fischer, and T. Brox, "U-Net: Convolutional networks for biomedical image segmentation" in *MICCAI 2015*, pp. 234–241, 2015.
- [12] J. C. van Rijn *et al.*, "Polyp miss rate determined by tandem colonoscopy: A systematic review" *American Journal of Gastroenterology*, vol. 101, no. 2, pp. 343–350, 2006.
- [13] Y. Zhang *et al.*, "TransFuse: Fusing transformers and CNNs for medical image segmentation," in *MICCAI 2021*, pp. 14–24, 2021.
- [14] Z. Zhou *et al.*, "UNet++: A nested U-Net architecture for medical image segmentation" in *MICCAI Workshop DLMIA*, pp. 3–11, 2018.